Cheat Sheet — Probabilidades e Estatística

LEIC — Resumo Completo (modo sobreviver mesmo)

Índice

1 - Estatística Descritiva 2
1.1 - Mediana, Quartis e IQR 2
1.2 - Tabelas de Frequência 3
2 - Probabilidades 3
2.1 - Probabilidade Total e Bayes com partição 3
2.2 - Combinatória 4
3 - Variáveis Aleatórias 4
3.1 - Binomial 5
3.2 - Geométrica 5
3.3 - Hipergeométrica 6
3.4 - Poisson 6
3.5 - Normal 7
3.6 - Uniforme Contínua 7
3.7 - Exponencial 8
3.8 - t-Student, Chi-quadrado e F 9
4 - Intervalos de Confiança 10
5 - Testes de Hipóteses 11
5.1 - Teste Chi-quadrado de Aderência 12
5.2 - Teste Chi-quadrado de Independência 12
5.3 - Teste F para Igualdade de Variâncias 12
6 - Duas Amostras 12
6.1 - Amostras Emparelhadas 13
7 - Correlação e Regressão Linear 14
7.1 - Coeficiente de Correlação de Pearson 14
7.2 - Regressão Linear ($\hat{y} = a + bx$) 14
7.3 - Decomposição 15
7.4 - Erro Padrão 15
7.5 - Intervalo Média vs Previsão 16
7.6 - Teste ao Declive 16

1 - Estatística Descritiva

Antes de começares a inventar regressões todas sexy, tens de saber fazer contas básicas sem falhar sinais.

Média:

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Variância amostral:

$$s^2 = \left(\frac{1}{n-1}\right) \sum_{i=1}^{n} (x_i - \overline{x})^2$$

Variância com n é da **população**. Com $(n-1)$ é da **amostra** — corrige o facto de a amostra subestimar sempre a variância real. Em exame é sempre $(n-1)$, a não ser que o enunciado diga explicitamente que tens a população toda.

Desvio padrão:

$$s = \sqrt{s^2}$$

Histograma: cada barra mostra quantas observações caem naquele valor. A linha vermelha é a média — percebe-se de imediato se a distribuição é simétrica ou não.

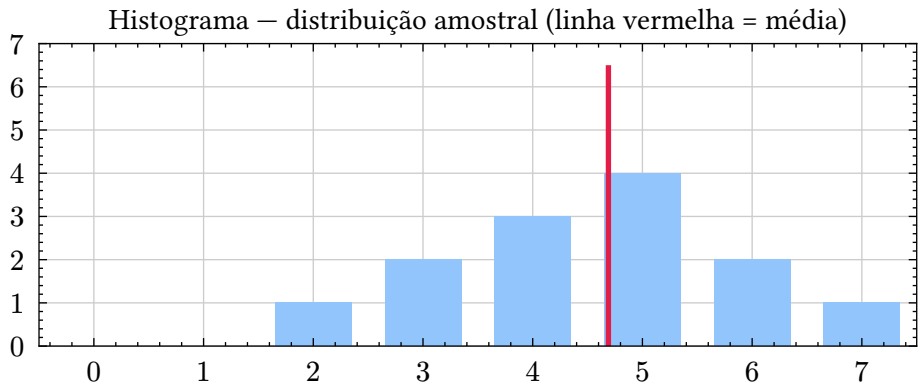

1.1 - Mediana, Quartis e IQR

Mediana: valor que parte a amostra ao meio. Não liga a outliers.

$$\text{Me} = \begin{cases} x_{\frac{n+1}{2}} & \text{se } n \text{ ímpar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & \text{se } n \text{ par} \end{cases}$$

Quartis: Q_1 (25%), Q_2 (mediana, 50%), Q_3 (75%).

Amplitude interquartil (robusta, ignora caudas):

$$\text{IQR} = Q_3 - Q_1$$

Outlier suspeito: abaixo de $Q_1 - 1.5 \cdot \text{IQR}$ ou acima de $Q_3 + 1.5 \cdot \text{IQR}$. Não é lei, é regra de bolso.

1.2 - Tabelas de Frequência

Valor	Freq. Abs.	Freq. Rel.	Freq. Acum.
x_i	n_i	$f_i = n_i/n$	$F_i = \sum_{j \leq i} f_j$

A frequência acumulada chega sempre a 1 no fim. Se não chegar, erraste nas contas.

2 - Probabilidades

$$P(A) = \frac{\text{casos favoraveis}}{\text{casos possiveis}}$$

$$P(A \text{ union } B) = P(A) + P(B) - P(A \text{ inter } B)$$

Probabilidade condicional (definição base — tudo deriva daqui):

$$P(A|B) = \frac{P(A \text{ inter } B)}{P(B)}$$

E o Bayes é só reorganizar isso:

$$P(A|B) = P(B|A)\frac{P(A)}{P(B)}$$

Independência significa que saber que B ocorreu não te diz nada sobre A. Se tens dúvida, verifica: $P(A \cap B) = P(A) \cdot P(B)$. Se a igualdade não se verificar, não são independentes.

Os dois círculos são A e B. A zona sobreposta (mais escura) é $A \cap B$. A zona total coberta é $A \cup B$.

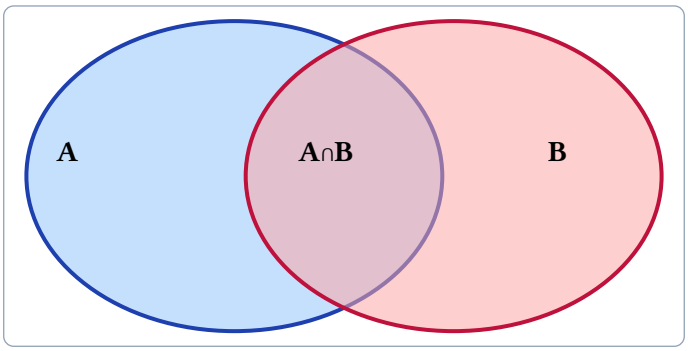

2.1 - Probabilidade Total e Bayes com partição

Se $B_1, \ldots, B_k$ formam uma partição de Ω:

$$P(A) = \sum_{i=1}^{k} P(A|B_i)P(B_i)$$

Útil quando chegas a A por vários caminhos. Somas as probabilidades de cada caminho.

As faixas B_1, B_2, B_3 particionam o espaço amostral. O evento A atravessa algumas delas — a probabilidade de A é a soma das fatias que atravessa.

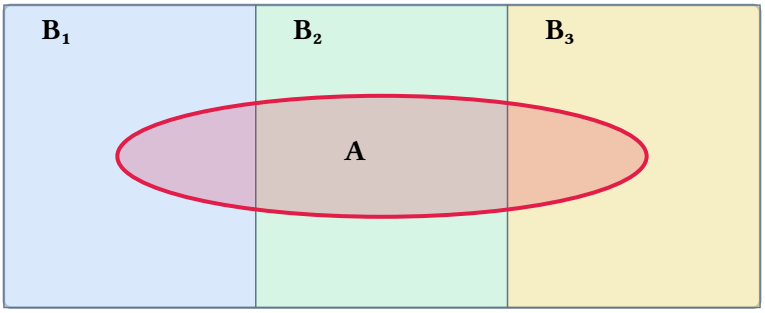

2.2 - Combinatória

Quando o espaço amostral são arranjos de objetos:

Permutações de n elementos distintos:

$$P_n = n!$$

Arranjos de n elementos tomados k a k (ordem importa):

$$A_n^k = \frac{n!}{(n-k)!}$$

Combinações de n elementos tomados k a k (ordem não importa):

$$C_n^k = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

> Se o enunciado diz "grupos", "comissões", "amostras" ⟶ combinações. Se diz "sequências", "ordenados" ⟶ arranjos.

Exemplo — arranjos de 2 de {A, B, C} (ordem importa):

1.º lugar	×	2.º lugar	=	3 × 2 = 6
3 opções		2 restantes		AB AC BA BC CA CB

Exemplo — combinações de 2 de {A, B, C} (ordem não importa):

6 arranjos	÷	2! = 2	=	3 combinações

AB e BA são a mesma coisa ⟶ só conta AB. Idem AC, BC.

3 - Variáveis Aleatórias

Esperança:

$$E(X) = \sum x_i p_i$$

Variância (forma inteligente):

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2$$

$\mathrm{Var}(X) = E(X^2) - (E(X))^2$ é a forma rápida. A outra ($\sum (x_i - \mu)^2 p_i$) dá o mesmo mas obriga a calcular a média primeiro e depois fazer a subtracção para cada termo — lento e com mais margem para erro.

3.1 - Binomial

$$X \sim \mathrm{Bin}(n, p)$$

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$E(X) = np$$

$$\mathrm{Var}(X) = np(1-p)$$

O gráfico mostra $P(X = k)$ para $n = 10$, $p = 0.3$. A barra mais alta está em $k = \lfloor np \rfloor = 3$, que é a moda da distribuição.

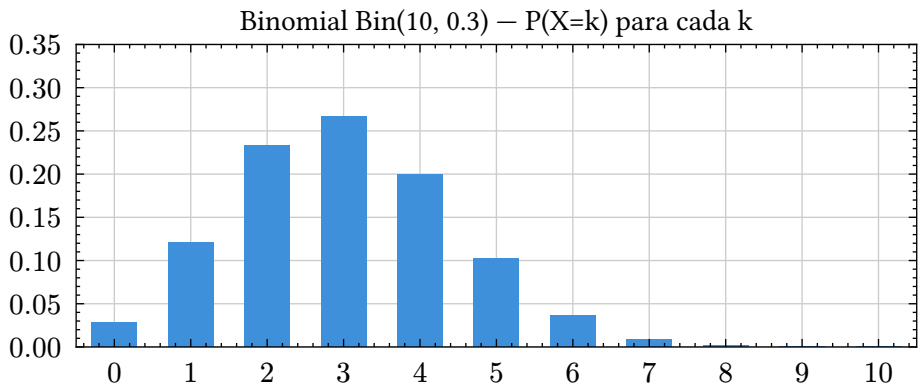

3.2 - Geométrica

Número de tentativas até ao primeiro sucesso:

$$X \sim \mathrm{Geom}(p)$$

$$P(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \ldots$$

$$E(X) = \frac{1}{p}$$

$$\mathrm{Var}(X) = \frac{1-p}{p^2}$$

Propriedade da falta de memória: $P(X > n + m \mid X > n) = P(X > m)$. O passado não conta. Útil para filas de espera e avarias.

Cada barra é $P(X = k) = (1-p)^{k-1} p$. A probabilidade decresce exponencialmente — a maioria dos sucessos chega cedo.

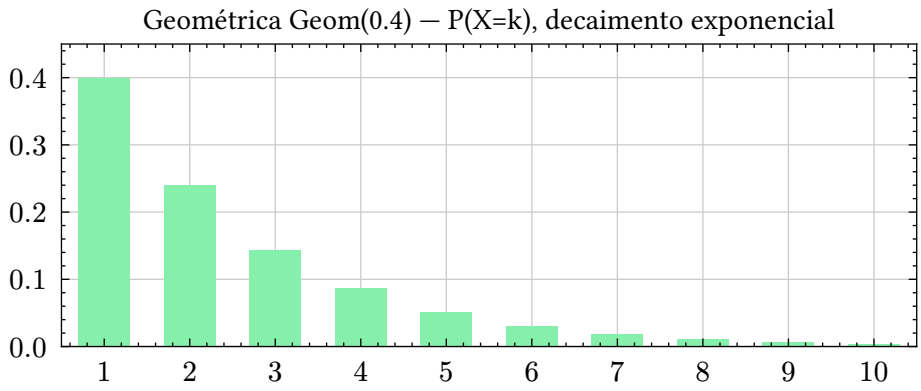

3.3 - Hipergeométrica

Amostragem sem reposição de uma população finita com N elementos, M "sucessos" e $N - M$ "falhas":

$$X \sim \text{HGeom}(N, M, n)$$

$$P(X = k) = \binom{M}{k} \frac{\binom{N-M}{n-k}}{\binom{N}{n}}$$

$$E(X) = n\frac{M}{N}$$

$$\text{Var}(X) = n\frac{M}{N}\left(1 - \frac{M}{N}\right)\frac{N-n}{N-1}$$

Usa Hipergeométrica quando a amostra é grande relativamente à população (sem reposição). Se $n/N < 0.05$, podes aproximar pela Binomial.

3.4 - Poisson

$$X \sim \text{Pois}(\lambda)$$

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

$$E(X) = \lambda$$

$$\text{Var}(X) = \lambda$$

Cada cor representa um λ diferente. Quanto maior o λ, mais a distribuição se desloca para a direita e achata. Para λ grande, a Poisson aproxima-se de uma Normal.

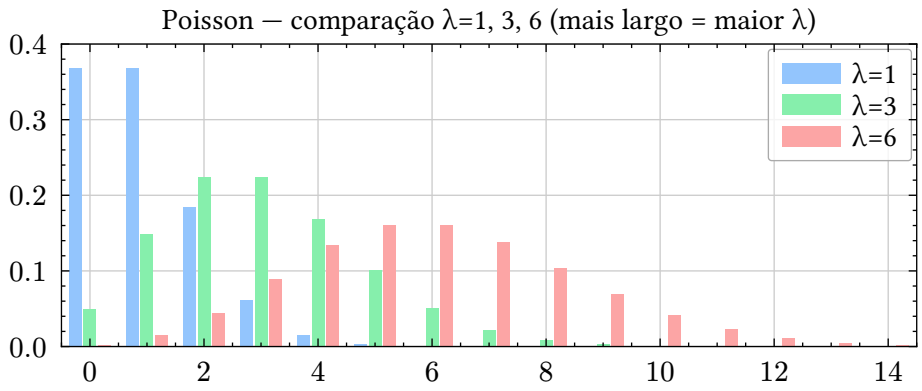

3.5 - Normal

$$X \sim \mathrm{N}(\mu, \sigma^2)$$

Padronização:

$$Z = \frac{X - \mu}{\sigma}$$

A curva é simétrica em torno de μ. A área total vale 1. Quando padronizas, $Z \sim \mathrm{N}(0, 1)$ e usas a tabela.

Para calcular probabilidades, padronizas e vais à tabela da Normal:

$$P(a < X < b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

$\Phi(z)$ é o valor da tabela da Normal para z. Lê bem a tabela — se for negativo, usa $\Phi(-z) = 1 - \Phi(z)$.

O valor que a tabela dá é sempre $P(Z \leq z)$, i.e., a área à **esquerda**. Desenha sempre um esboço antes de calcular para não te enganares no sinal.

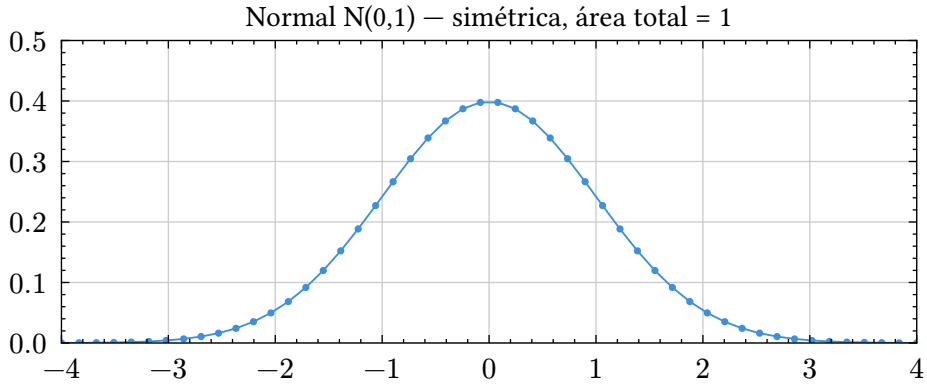

3.6 - Uniforme Contínua

$$X \sim \mathrm{U}(a, b)$$

$$f(x) = \frac{1}{b - a}, \quad x \in [a, b]$$

$$E(X) = \frac{a+b}{2}, \quad \mathrm{Var}(X) = \frac{(b-a)^2}{12}$$

$$P(X \leq x) = \frac{x-a}{b-a}$$

Todos os valores no intervalo são igualmente prováveis. O gerador de números aleatórios do computador é $U(0,1)$.

A densidade é constante entre a e b — um rectângulo. Fora desse intervalo é zero.

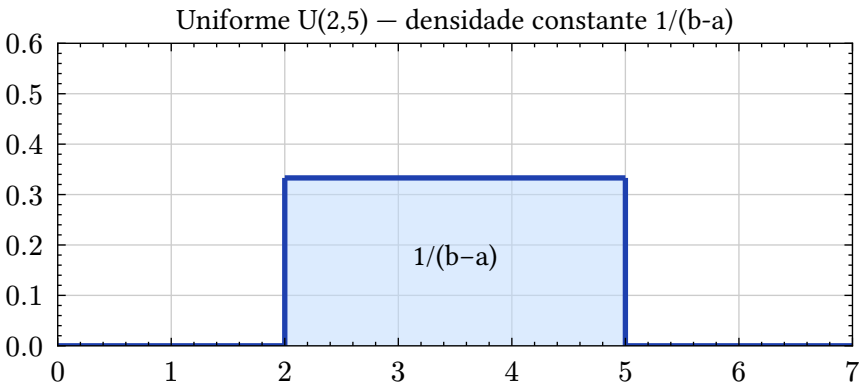

3.7 - Exponencial

Modela o tempo até ao próximo evento (complementar da Poisson):

$$X \sim \mathrm{Exp}(\lambda)$$

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$E(X) = \frac{1}{\lambda}, \quad \mathrm{Var}(X) = \frac{1}{\lambda^2}$$

$$P(X > x) = e^{-\lambda x}$$

$$P(X \leq x) = 1 - e^{-\lambda x}$$

Também tem falta de memória: $P(X > s + t \mid X > s) = P(X > t)$. Mesma propriedade da Geométrica, mas contínua.

A curva decresce rapidamente. A área sombreada até $x = 1$ é $P(X \leq 1) = 1 - e^{\{-\lambda\}}$.

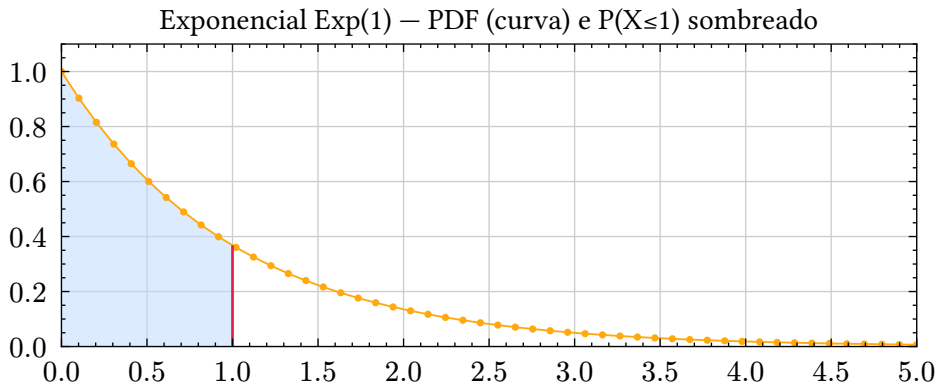

3.8 - t-Student, Chi-quadrado e F

Estas distribuições saem naturalmente quando trabalhas com amostras pequenas e variâncias desconhecidas.

$T = \frac{\overline{X}-\mu}{S/\sqrt{n}} \sim t_{n-1}$ — usas nos IC e testes com σ desconhecido.

$\chi^2 = (n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$ — usas para fazer inferência sobre variâncias.

$F = \chi^2_{\nu_1}/\nu_1 / \left(\chi^2_{\nu_2}/\nu_2\right) \sim F_{\nu_1,\nu_2}$ — usas para comparar duas variâncias.

Não confundas os graus de liberdade. t tem $n-1$. Chi-quadrado tem $n-1$. F tem dois: (n_1-1) e (n_2-1).

A t-Student tem caudas mais pesadas que a Normal — quanto menor o n, mais gorda a cauda. Com $n > 30$ já é quase Normal.

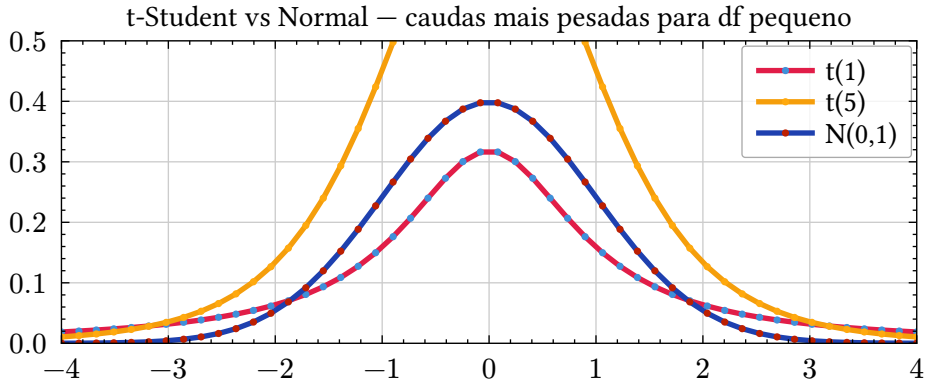

A chi-quadrado é sempre não-negativa e assimétrica. Com df maior fica mais parecida com uma Normal.

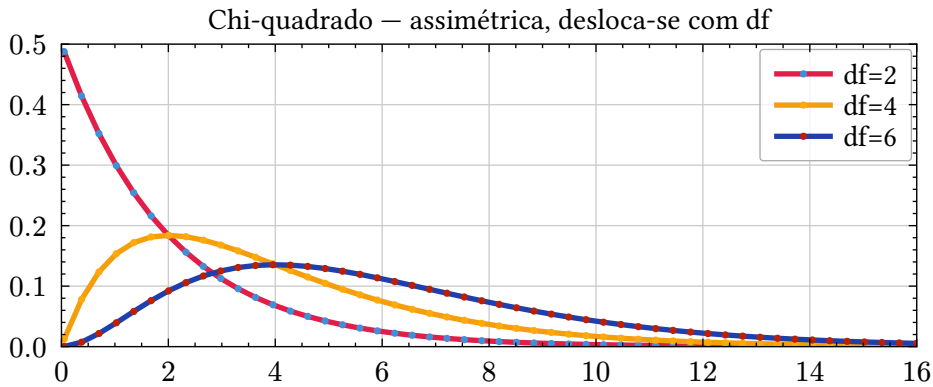

4 - Intervalos de Confiança

Estrutura mental: estimativa ± margem de erro.

Usa z quando σ é **conhecida**. Usa t quando σ é **desconhecida** (quase sempre):

$$\overline{x} \pm z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \quad (\sigma \text{ conhecida})$$

$$\overline{x} \pm t_{n-1,1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}} \quad (\sigma \text{ desconhecida, tabela t com n-1 gl})$$

$$\hat{p} \pm z_{1-\frac{\alpha}{2}} \sqrt{\hat{p}\frac{1-\hat{p}}{n}}$$

IC para variância (σ^2 desconhecida, usa chi-quadrado):

$$\left((n-1)\frac{s^2}{\chi^2_{n-1,1-\frac{\alpha}{2}}}, (n-1)\frac{s^2}{\chi^2_{n-1,\frac{\alpha}{2}}} \right)$$

O IC da variância não é simétrico — a chi-quadrado é assimétrica. Os dois limites usam quantis diferentes: $\chi^2_{\frac{\alpha}{2}}$ (esquerda) e $\chi^2_{1-\frac{\alpha}{2}}$ (direita). E os limites ficam **invertidos** porque divides por eles.

A região sombreada é o IC da variância. Os dois cortes verticais são $\chi^2_{\frac{\alpha}{2}}$ e $\chi^2_{1-\frac{\alpha}{2}}$. Os limites do IC ficam invertidos (divide-se por eles).

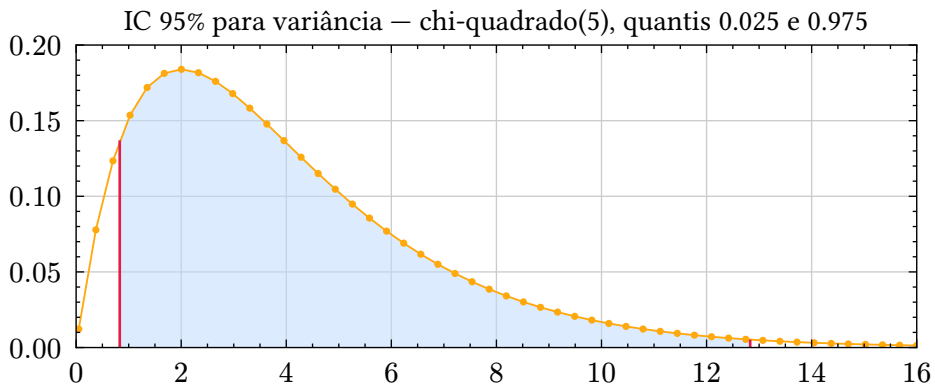

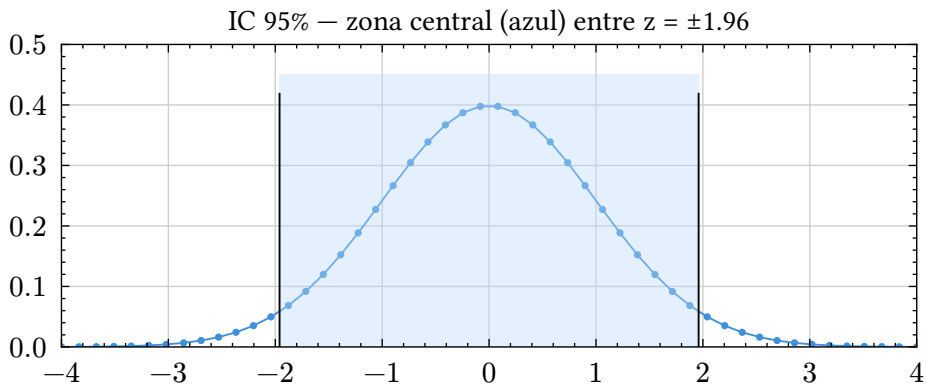

"95% de confiança" não quer dizer que há 95% de probabilidade de o parâmetro estar no intervalo. O parâmetro ou está ou não está — não tem probabilidade. O que tem 95% é o **método**: se repetisses o estudo muitas vezes, 95% dos intervalos calculados conteriam o parâmetro real.

5 - Testes de Hipóteses

Primeiro defines as hipóteses. Sempre. Sem isto não há teste.

Teste à média (σ desconhecida):

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \begin{cases} \mu \neq \mu_0 \text{ (bilateral)} \\ \mu > \mu_0 \text{ (unilateral direita)} \\ \mu < \mu_0 \text{ (unilateral esquerda)} \end{cases}$$

$$t_0 = \frac{\overline{x} - \mu_0}{\frac{s}{\sqrt{n}}} \quad \sim \quad t_{n-1}$$

Regra de decisão: rejeitas H_0 se:
- bilateral: $|t_0| > t_{n-1,1-\frac{\alpha}{2}}$
- unilateral direita: $t_0 > t_{n-1,1-\alpha}$
- unilateral esquerda: $t_0 < -t_{n-1,1-\alpha}$

Teste à proporção:

$$H_0 : p = p_0$$

$$z_0 = \frac{\hat{p} - p_0}{\sqrt{p_0 \frac{1-p_0}{n}}} \quad \sim \quad \mathrm{N}(0,1)$$

Mesma regra mas com z em vez de t.

Teste para a variância (usa chi-quadrado):

$$\chi_0^2 = (n-1)\frac{s^2}{\sigma_0^2}$$

Rejeitas $H_0 : \sigma^2 = \sigma_0^2$ se χ_0^2 cair fora da zona de aceitação da tabela chi-quadrado.

Se p-value $< \alpha \longrightarrow$ rejeitas H_0.

"Não rejeitar H_0" não é o mesmo que "provar H_0". Significa apenas que não há evidência suficiente nos dados para a rejeitar. É como um julgamento: absolvido não é inocente, é "não provado culpado".

As áreas a vermelho são a zona de rejeição. Se o teu z_0 cair ali, rejeitas. Se cair no meio, não rejeitas — mas não provaste nada.

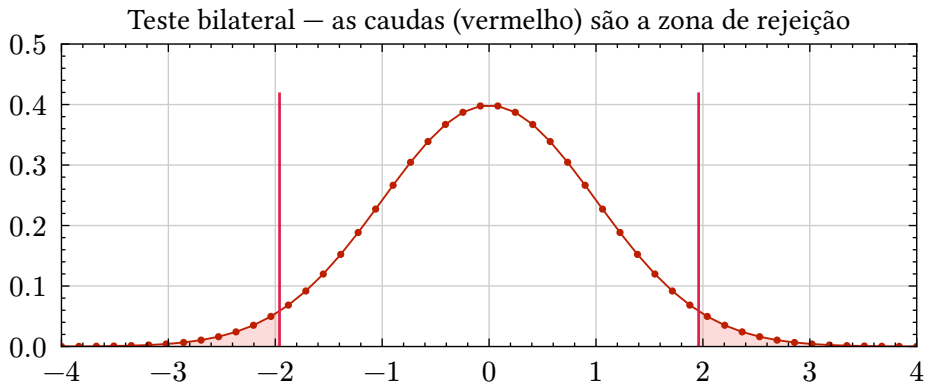

5.1 - Teste Chi-quadrado de Aderência

Verifica se os dados seguem uma distribuição teórica (ex.: será que isto é mesmo Poisson?):

$$\chi_0^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

Onde O_i são as frequências observadas e $E_i = np_i$ as esperadas. Graus de liberdade: $k - 1 -$ parâmetros estimados.

Regra de decisão: rejeitas H_0 se $\chi_0^2 > \chi^2_{k-1,1-\alpha}$ (unilateral — cauda direita sempre).

> Para usar este teste, cada $E_i \geq 5$. Se não, agrupa classes. Se te esqueceres disto, o examinador não se esquece.

5.2 - Teste Chi-quadrado de Independência

Dois critérios (ex.: género vs. preferência) são independentes?

$$\chi_0^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \text{total linha} \times \frac{\text{total coluna}}{n}$$

Graus de liberdade: $(r-1)(c-1)$, onde r = linhas e c = colunas.

Regra de decisão: rejeitas H_0 se $\chi_0^2 > \chi^2_{(r-1)(c-1),1-\alpha}$.

5.3 - Teste F para Igualdade de Variâncias

$$H_0 : \sigma_1^2 = \sigma_2^2$$

$$F_0 = \frac{s_1^2}{s_2^2}$$

Põe sempre a maior variância no numerador (garante $F_0 > 1$). Rejeitas H_0 se $F_0 > F_{\frac{\alpha}{2},n_1-1,n_2-1}$ — como puseste a maior em cima, só precisas da cauda direita.

> Deves fazer este teste antes do teste t de duas amostras para decidir se usas variâncias iguais ou diferentes.

6 - Duas Amostras

Variâncias iguais (graus de liberdade: $n_1 + n_2 - 2$):

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

$$t_0 = \frac{\overline{x}_1 - \overline{x}_2}{s_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

IC para a diferença de médias (variâncias iguais):

$$(\overline{x}_1 - \overline{x}_2) \pm t_{n_1+n_2-2,1-\frac{\alpha}{2}} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

Variâncias diferentes — graus de liberdade de Welch-Satterthwaite (não é $n_1 + n_2 - 2$):

$$t_0 = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

$$\nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2-1}}$$

IC para a diferença de médias (variâncias diferentes):

$$(\overline{x}_1 - \overline{x}_2) \pm t_{\nu,1-\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Regra de decisão para qualquer dos dois: rejeitas $H_0 : \mu_1 = \mu_2$ se $|t_0| > t_{\text{gl},1-\frac{\alpha}{2}}$.

As duas curvas representam as distribuições das duas populações. Se estiverem muito sobrepostas, não há evidência de diferença entre as médias.

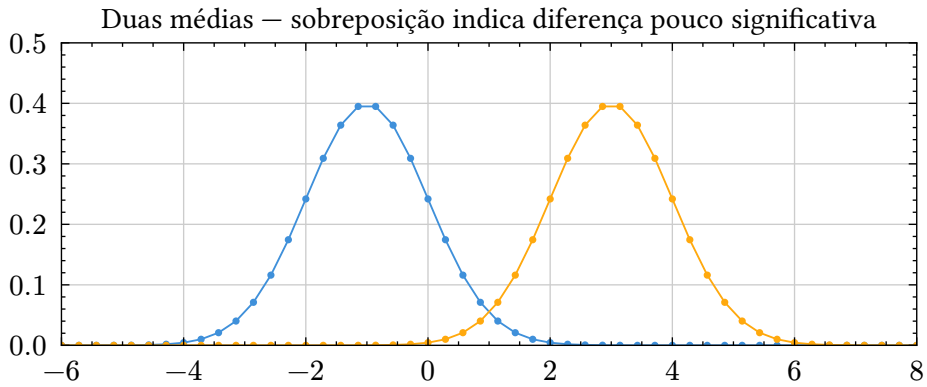

6.1 - Amostras Emparelhadas

Quando cada observação da amostra 1 tem um par natural na amostra 2 (ex.: antes/depois, esquerda/direita):

$$H_0 : \mu_d = 0 \quad \text{vs} \quad H_1 : \mu_d \neq 0$$

$$d_i = x_{1i} - x_{2i}$$

$$t_0 = \frac{\overline{d}}{\frac{s_d}{\sqrt{n}}} \quad \sim \quad t_{n-1}$$

Rejeitas H_0 se $|t_0| > t_{n-1,1-\frac{\alpha}{2}}$.

Não confundas com duas amostras independentes. Se os dados têm pares naturais, és obrigado a usar o teste emparelhado. Se usares o outro, estás a desperdiçar informação e a fazer o examinador chorar.

7 - Correlação e Regressão Linear

A regressão serve para modelar a relação entre duas variáveis e fazer previsões. A correlação mede se essa relação existe e quão forte é.

7.1 - Coeficiente de Correlação de Pearson

Mede a força e direcção da relação linear entre x e y:

$$r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}}$$

$r \in [-1, 1]$. Perto de $\pm 1 \longrightarrow$ correlação forte. Perto de $0 \longrightarrow$ relação linear fraca (pode existir relação não linear).

Em exame, quando te pedem para **interpretar** r: "Existe uma correlação linear forte/fraca, positiva/negativa entre x e y." Para $|r| > 0.8$ diz forte, para $|r| < 0.5$ diz fraca. Entre os dois, moderada.

Os três exemplos mostram o que r significa visualmente. Quanto mais alinhados, mais perto de ± 1.

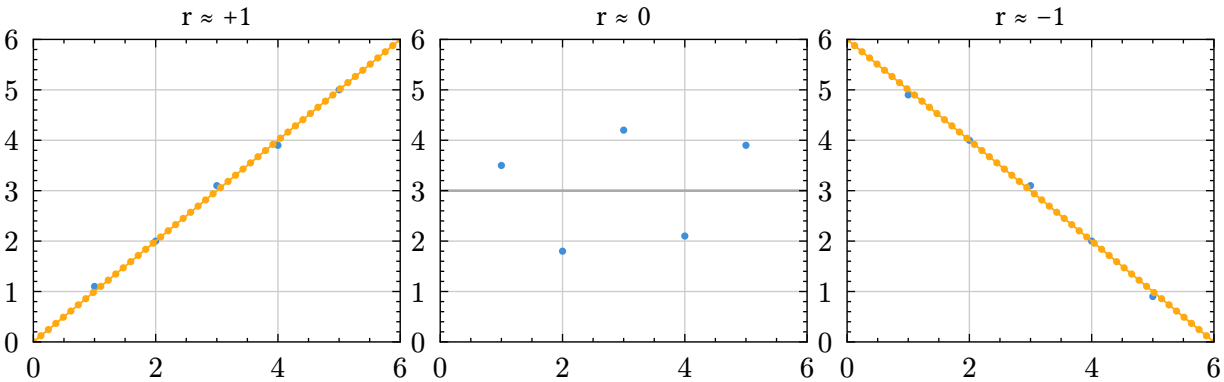

7.2 - Regressão Linear ($\hat{y} = a + bx$)

Calculas $\hat{y} = a + bx$ — desmontas a coisa nesta ordem: $\overline{x}$, $\overline{y}$, S_{xx}, S_{xy}, b, a. Sempre por esta sequência.

Médias (precisas delas para tudo o resto):

$$\overline{x} = \frac{\sum x_i}{n}, \quad \overline{y} = \frac{\sum y_i}{n}$$

$$a = \overline{y} - b\overline{x}$$

$$b = \frac{S_{xy}}{S_{xx}}$$

$$S_{xx} = \sum x_i^2 - n\overline{x}^2$$

$$S_{xy} = \sum x_i y_i - n\overline{xy}$$

$$S_{yy} = \sum y_i^2 - n\overline{y}^2$$

S_{yy} parece inútil na regressão, mas precisas dela para calcular $r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}}$. Não te esqueças.

Declive b é quanto y sobe quando x aumenta 1 unidade.

Ordenada a é o valor quando $x = 0$. Se $x = 0$ não fizer sentido, não inventes física alternativa.

Em exame, quando te pedem para **interpretar** b: "Por cada aumento de 1 unidade em x, y aumenta/diminui em média b unidades." Não escrevas só o número — o examinador quer a frase completa com as unidades certas.

7.3 - Decomposição

$$\text{SQT} = \text{SQR} + \text{SQE}$$

$$R^2 = \frac{\text{SQR}}{\text{SQT}}$$

Como calcular cada um:

$$\text{SQT} = S_{yy} = \sum y_i^2 - n\overline{y}^2$$

$$\text{SQR} = b^2 S_{xx} = b \cdot S_{xy}$$

$$\text{SQE} = \text{SQT} - \text{SQR}$$

Na prática: calculas S_{yy}, calculas $b \cdot S_{xy}$, subtrais. Nunca calculas o SQE directamente — é sempre resíduo.

A barra azul é o SQT total. A parte azul-clara é o SQR (variação explicada pelo modelo) e a parte vermelha é o SQE (variação residual). R^2 = proporção azul-clara sobre o total.

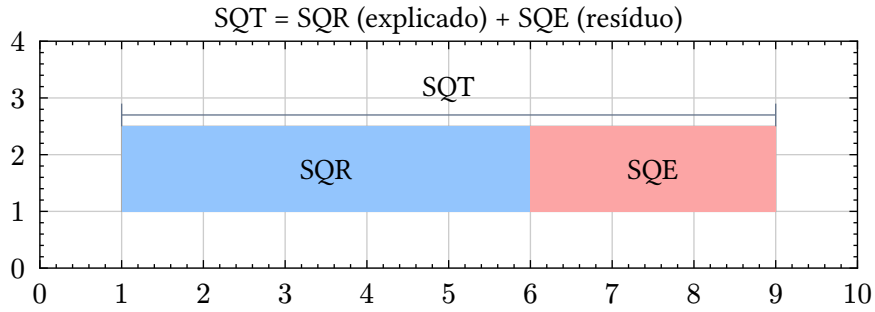

7.4 - Erro Padrão

$$s_{y.x} = \sqrt{\frac{\text{SQE}}{n-2}}$$

$$s_b = \frac{s_{y.x}}{\sqrt{S_{xx}}}$$

7.5 - Intervalo Média vs Previsão

$$\hat{y}_0 \pm t_{n-2,1-\frac{\alpha}{2}} s_{y.x} \sqrt{\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}}$$

$$\hat{y}_0 \pm t_{n-2,1-\frac{\alpha}{2}} s_{y.x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}}$$

O segundo IC (previsão individual) é sempre maior do que o IC da média porque inclui a variabilidade do ponto individual, não só a incerteza sobre a média. Se o enunciado pede "previsão para um novo valor", usa o segundo. Se pede "valor médio esperado para x_0", usa o primeiro.

7.6 - Teste ao Declive

$$H_0 : \beta_1 = 0$$

$$t_0 = \frac{b}{s_b}$$

Se rejeitares H_0, há evidência de relação linear.

Se não rejeitares, não provaste nada.

Regra de decisão: rejeitas H_0 se $|t_0| > t_{n-2,1-\frac{\alpha}{2}}$.

Os pontos são dados reais; a linha é a reta ajustada $\hat{y} = -0.53 + 0.26x$. Quanto mais próximos os pontos da reta, maior o R^2.

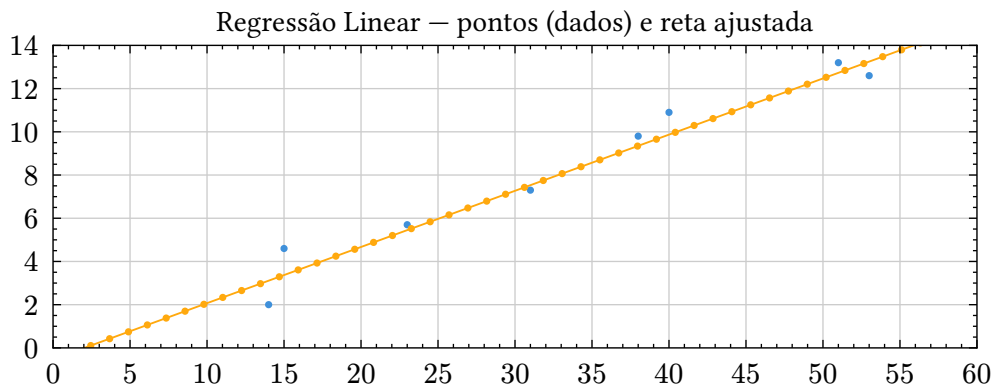

Cada ponto é $\hat{y}_i$ no eixo x contra o resíduo $e_i = y_i - \hat{y}_i$ no eixo y. Ideal: pontos dispersos aleatoriamente em torno da linha vermelha (zero). Padrão em arco = modelo errado.

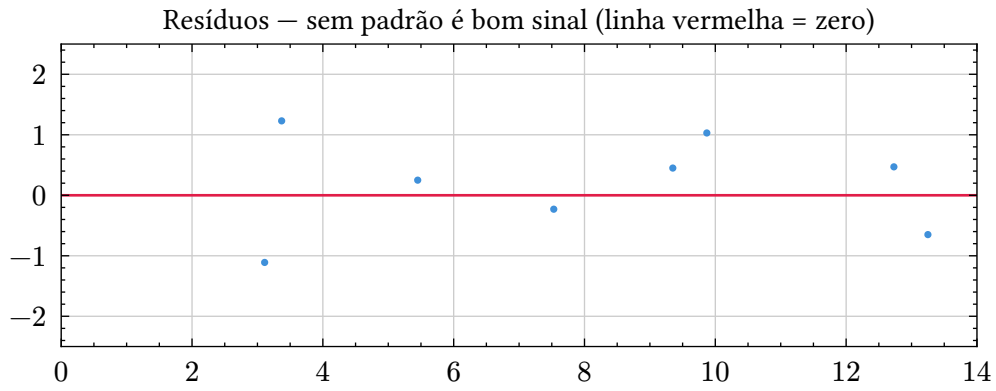

Resíduos devem ter padrão aleatório em torno de zero. Se tiverem curva, o modelo linear não chega.

Agora tens tudo. Usa o índice para navegar.